

# 尚硅谷大数据技术之 HBase

(作者: 尚硅谷大数据研发部)

版本: V1.3

# 第1章 HBase 简介

## 1.1 HBase 定义

HBase 是一种分布式、可扩展、支持海量数据存储的 NoSQL 数据库。

## 1.2 HBase 数据模型

逻辑上,HBase 的数据模型同关系型数据库很类似,数据存储在一张表中,有行有列。 但从 HBase 的底层物理存储结构(K-V)来看,HBase 更像是一个 multi-dimensional map。

## 1.2.1 HBase 逻辑结构



## 1.2.2 HBase 物理存储结构





## 1.2.3 数据模型

#### 1) Name Space

命名空间,类似于关系型数据库的 DatabBase 概念,每个命名空间下有多个表。HBase 有两个自带的命名空间,分别是 hbase 和 default, hbase 中存放的是 HBase 内置的表, default 表是用户默认使用的命名空间。

#### 2) Region

类似于关系型数据库的表概念。不同的是,HBase 定义表时只需要声明列族即可,不需要声明具体的列。这意味着,往 HBase 写入数据时,字段可以动态、按需指定。因此,和关系型数据库相比,HBase 能够轻松应对字段变更的场景。

#### 3) Row

HBase 表中的每行数据都由一个 RowKey 和多个 Column (列)组成,数据是按照 RowKey 的字典顺序存储的,并且查询数据时只能根据 RowKey 进行检索,所以 RowKey 的设计十分重要。

#### 4) Column

HBase 中的每个列都由 Column Family (列族)和 Column Qualifier (列限定符)进行限定,例如 info: name, info: age。建表时,只需指明列族,而列限定符无需预先定义。

#### 5) Time Stamp

用于标识数据的不同版本(version),每条数据写入时,如果不指定时间戳,系统会自动为其加上该字段,其值为写入 HBase 的时间。

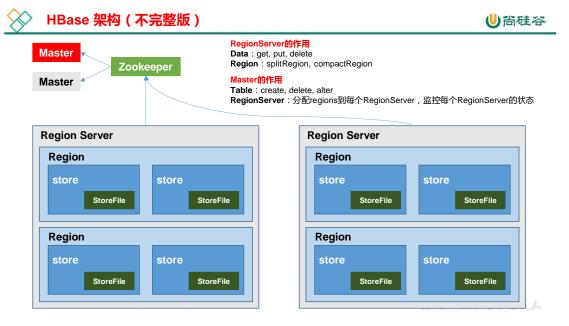
更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



#### 6) Cell

由{rowkey, column Family: column Qualifier, time Stamp} 唯一确定的单元。cell 中的数据是没有类型的,全部是字节码形式存贮。

## 1.3 HBase 基本架构



#### 架构角色:

#### 1) Region Server

Region Server 为 Region 的管理者,其实现类为 HRegionServer,主要作用如下: 对于数据的操作: get, put, delete;

对于 Region 的操作: splitRegion、compactRegion。

#### 2) Master

Master 是所有 Region Server 的管理者,其实现类为 HMaster,主要作用如下: 对于表的操作: create, delete, alter

对于 RegionServer 的操作: 分配 regions 到每个 RegionServer, 监控每个 RegionServer 的状态, 负载均衡和故障转移。

#### 3) Zookeeper

HBase 通过 Zookeeper 来做 Master 的高可用、RegionServer 的监控、元数据的入口以及 集群配置的维护等工作。

#### 4) HDFS

HDFS 为 HBase 提供最终的底层数据存储服务,同时为 HBase 提供高可用的支持。

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



## 第2章 HBase 快速入门

## 2.1 HBase 安装部署

## 2.1.1 Zookeeper 正常部署

首先保证 Zookeeper 集群的正常部署,并启动之:

```
[atguigu@hadoop102 zookeeper-3.4.10]$ bin/zkServer.sh start [atguigu@hadoop103 zookeeper-3.4.10]$ bin/zkServer.sh start [atguigu@hadoop104 zookeeper-3.4.10]$ bin/zkServer.sh start
```

## 2.1.2 Hadoop 正常部署

Hadoop 集群的正常部署并启动:

```
[atguigu@hadoop102 hadoop-2.7.2]$ sbin/start-dfs.sh [atguigu@hadoop103 hadoop-2.7.2]$ sbin/start-yarn.sh
```

## 2.1.3 HBase 的解压

解压 Hbase 到指定目录:

```
[atguigu@hadoop102 software]$ tar -zxvf hbase-1.3.1-bin.tar.gz -C /opt/module
```

## 2.1.4 HBase 的配置文件

修改 HBase 对应的配置文件。

1) hbase-env.sh 修改内容:

```
export JAVA_HOME=/opt/module/jdk1.6.0_144
export HBASE MANAGES ZK=false
```

2) hbase-site.xml 修改内容:

```
<configuration>
   cproperty>
      <name>hbase.rootdir</name>
      <value>hdfs://hadoop102:9000/HBase</value>
   </property>
   property>
      <name>hbase.cluster.distributed
      <value>true</value>
   </property>
  <!-- 0.98 后的新变动,之前版本没有.port,默认端口为 60000 -->
   cproperty>
      <name>hbase.master.port
      <value>16000</value>
   </property>
   cproperty>
      <name>hbase.zookeeper.quorum</name>
       <value>hadoop102, hadoop103, hadoop104</value>
```



#### 3) regionservers:

```
hadoop102
hadoop103
hadoop104
```

#### 4) 软连接 hadoop 配置文件到 HBase:

```
[atguigu@hadoop102 module]$ ln -s /opt/module/hadoop-
2.7.2/etc/hadoop/core-site.xml /opt/module/hbase/conf/core-
site.xml
[atguigu@hadoop102 module]$ ln -s /opt/module/hadoop-
2.7.2/etc/hadoop/hdfs-site.xml /opt/module/hbase/conf/hdfs-
site.xml
```

## 2.1.5 HBase 远程发送到其他集群

[atguigu@hadoop102 module]\$ xsync hbase/

## 2.1.6 HBase 服务的启动

ClockOutOfSyncException异常。

#### 1. 启动方式

[atguigu@hadoop102 hbase]\$ bin/hbase-daemon.sh start master [atguigu@hadoop102 hbase]\$ bin/hbase-daemon.sh start regionserver

提示: 如果集群之间的节点时间不同步,会导致 regionserver 无法启动,抛出

### 修复提示:

a、同步时间服务

#### 请参看帮助文档:《尚硅谷大数据技术之 Hadoop 入门》

b、属性: hbase.master.maxclockskew 设置更大的值

#### 2. 启动方式 2

```
[atguigu@hadoop102 hbase] $ bin/start-hbase.sh
```

对应的停止服务:

[atguigu@hadoop102 hbase]\$ bin/stop-hbase.sh

## 2.1.7 查看 HBase 页面



启动成功后,可以通过"host:port"的方式来访问 HBase 管理页面,例如:

http://hadoop102:16010

## 2.2 HBase Shell 操作

## 2.2.1 基本操作

### 1. 进入 HBase 客户端命令行

[atguigu@hadoop102 hbase]\$ bin/hbase shell

#### 2. 查看帮助命令

hbase(main):001:0> help

#### 3. 查看当前数据库中有哪些表

hbase(main):002:0> list

## 2.2.2 表的操作

#### 1. 创建表

hbase(main):002:0> create 'student','info'

#### 2. 插入数据到表

```
hbase(main):003:0> put 'student','1001','info:sex','male'
hbase(main):004:0> put 'student','1001','info:age','18'
hbase(main):005:0> put 'student','1002','info:name','Janna'
hbase(main):006:0> put 'student','1002','info:sex','female'
hbase(main):007:0> put 'student','1002','info:age','20'
```

#### 3. 扫描查看表数据

```
hbase(main):008:0> scan 'student'
hbase(main):009:0> scan 'student',{STARTROW => '1001', STOPROW =>
'1001'}
hbase(main):010:0> scan 'student',{STARTROW => '1001'}
```

#### 4. 查看表结构

hbase(main):011:0> describe 'student'

#### 5. 更新指定字段的数据

```
hbase(main):012:0> put 'student','1001','info:name','Nick' hbase(main):013:0> put 'student','1001','info:age','100'
```

#### 6. 杳看"指定行"或"指定列族:列"的数据

```
hbase(main):014:0> get 'student','1001'
hbase(main):015:0> get 'student','1001','info:name'
```

#### 7. 统计表数据行数

hbase(main):021:0> count 'student'

#### 8. 删除数据

删除某 rowkey 的全部数据:

```
hbase(main):016:0> deleteall 'student','1001'
```

删除某 rowkey 的某一列数据:



hbase(main):017:0> delete 'student','1002','info:sex'

#### 9. 清空表数据

hbase(main):018:0> truncate 'student'

提示: 清空表的操作顺序为先 disable, 然后再 truncate。

#### 10. 删除表

首先需要先让该表为 disable 状态:

hbase(main):019:0> disable 'student'

然后才能 drop 这个表:

hbase(main):020:0> drop 'student'

提示: 如果直接 drop 表, 会报错: ERROR: Table student is enabled. Disable it first.

#### 11. 变更表信息

将 info 列族中的数据存放 3 个版本:

```
hbase(main):022:0> alter 'student', {NAME=>'info', VERSIONS=>3}
hbase(main):022:0> get
'student','1001', {COLUMN=>'info:name', VERSIONS=>3}
```

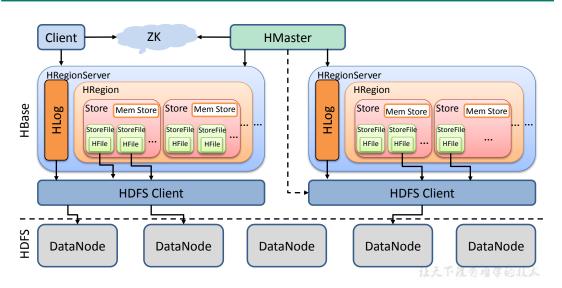
## 第3章 HBase 进阶

## 3.1 架构原理



HBase详细架构图





#### 1) StoreFile

保存实际数据的物理文件,StoreFile 以 HFile 的形式存储在 HDFS 上。每个 Store 会有一个或多个 StoreFile (HFile),数据在每个 StoreFile 中都是有序的。

#### 2) MemStore

写缓存,由于 HFile 中的数据要求是有序的,所以数据是先存储在 MemStore 中,排好

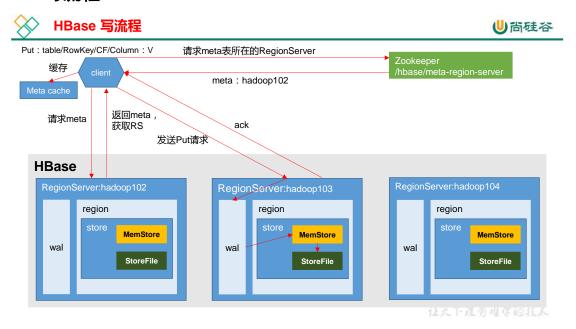


序后,等到达刷写时机才会刷写到 HFile,每次刷写都会形成一个新的 HFile。

#### 3) WAL

由于数据要经 MemStore 排序后才能刷写到 HFile,但把数据保存在内存中会有很高的概率导致数据丢失,为了解决这个问题,数据会先写在一个叫做 Write-Ahead logfile 的文件中,然后再写入 MemStore 中。所以在系统出现故障的时候,数据可以通过这个日志文件重建。

## 3.2 写流程



### 写流程:

- 1) Client 先访问 zookeeper,获取 hbase:meta 表位于哪个 Region Server。
- 2) 访问对应的 Region Server, 获取 hbase:meta 表,根据读请求的 namespace:table/rowkey, 查询出目标数据位于哪个 Region Server 中的哪个 Region 中。并将该 table 的 region 信息以 及 meta 表的位置信息缓存在客户端的 meta cache, 方便下次访问。
- 3) 与目标 Region Server 进行通讯;
- 4) 将数据顺序写入(追加)到 WAL;
- 5) 将数据写入对应的 MemStore, 数据会在 MemStore 进行排序;
- 6) 向客户端发送 ack;
- 7)等达到 MemStore 的刷写时机后,将数据刷写到 HFile。

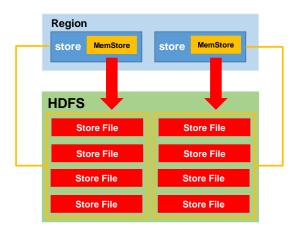


#### 3.3 MemStore Flush



**MemStore Flush** 





让天下没有难学的技术

#### MemStore 刷写时机:

1.当某个 memstroe 的大小达到了 hbase.hregion.memstore.flush.size(默认值 128M), 其所在 region 的所有 memstore 都会刷写。

当 memstore 的大小达到了

hbase.hregion.memstore.flush.size (默认值 128M)

- \* hbase.hregion.memstore.block.multiplier (默认值 4)
- 时,会阻止继续往该 memstore 写数据。
  - 2.当 region server 中 memstore 的总大小达到

#### java heapsize

\*hbase.regionserver.global.memstore.size (默认值 0.4)

\*hbase.regionserver.global.memstore.size.lower.limit(默认值 0.95),

region 会按照其所有 memstore 的大小顺序(由大到小)依次进行刷写。直到 region server 中所有 memstore 的总大小减小到上述值以下。

当 region server 中 memstore 的总大小达到

java\_heapsize\*hbase.regionserver.global.memstore.size (默认值 0.4)

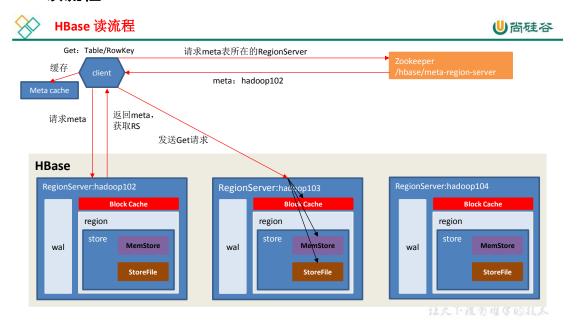
- 时,会阻止继续往所有的 memstore 写数据。
- 3. 到达自动刷写的时间,也会触发 memstore flush。自动刷新的时间间隔由该属性进行配置 hbase.regionserver.optionalcacheflushinterval(默认 1 小时)。

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



4.当 WAL 文件的数量超过 hbase.regionserver.max.logs, region 会按照时间顺序依次进行刷写, 直到 WAL 文件数量减小到 hbase.regionserver.max.log 以下(该属性名已经废弃,现无需手动设置,最大值为 32)。

## 3.4 读流程



#### 读流程

- 1) Client 先访问 zookeeper,获取 hbase:meta 表位于哪个 Region Server。
- 2) 访问对应的 Region Server, 获取 hbase:meta 表,根据读请求的 namespace:table/rowkey, 查询出目标数据位于哪个 Region Server 中的哪个 Region 中。并将该 table 的 region 信息以 及 meta 表的位置信息缓存在客户端的 meta cache, 方便下次访问。
- 3) 与目标 Region Server 进行通讯;
- 4)分别在 Block Cache(读缓存),MemStore 和 Store File(HFile)中查询目标数据,并将查到的所有数据进行合并。此处所有数据是指同一条数据的不同版本(time stamp)或者不同的类型(Put/Delete)。
- 5) 将从文件中查询到的数据块(Block,HFile 数据存储单元,默认大小为 64KB)缓存到 Block Cache。
- 6) 将合并后的最终结果返回给客户端。

## 3.5 StoreFile Compaction

由于 memstore 每次刷写都会生成一个新的 HFile,且同一个字段的不同版本(timestamp)和不同类型(Put/Delete)有可能会分布在不同的 HFile 中,因此查询时需要遍历所有的 HFile。

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



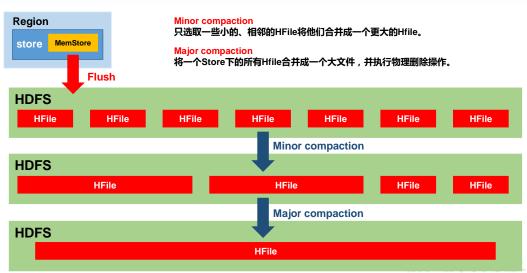
为了减少 HFile 的个数,以及清理掉过期和删除的数据,会进行 StoreFile Compaction。

Compaction 分为两种,分别是 Minor Compaction 和 Major Compaction。Minor Compaction 会将临近的若干个较小的 HFile 合并成一个较大的 HFile,但不会清理过期和删除的数据。 Major Compaction 会将一个 Store 下的所有的 HFile 合并成一个大 HFile,并且会清理掉过期和删除的数据。



#### **StoreFile Compaction**





## 3.6 Region Split

默认情况下,每个 Table 起初只有一个 Region,随着数据的不断写入,Region 会自动进行拆分。刚拆分时,两个子 Region 都位于当前的 Region Server,但处于负载均衡的考虑,HMaster 有可能会将某个 Region 转移给其他的 Region Server。

Region Split 时机:

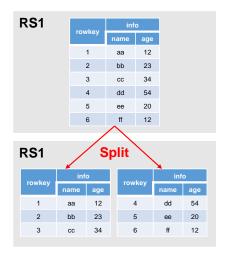
- 1.当1个region中的某个Store下所有StoreFile的总大小超过hbase.hregion.max.filesize,该Region就会进行拆分(0.94版本之前)。
- 2. 当 1 个 region 中的某个 Store 下所有 StoreFile 的总大小超过 Min(R^2 \* "hbase.hregion.memstore.flush.size",hbase.hregion.max.filesize"),该 Region 就会进行拆分,其中 R 为当前 Region Server 中属于该 Table 的个数(0.94 版本之后)。





#### **Region Split**





1.当1个region中的某个Store下所有StoreFile的总大小超过" hbase.hregion.max.filesize " , 该region就会进行拆分 ( 0.94版之前 )

2.当1个region中的某个Store下所有StoreFile的总大小超过Min(R^2\*"hbase.hregion.memstore.flush.size", "hbase.hregion.max.filesize") 就会拆分,其中R为当前RegionServer中属于该table的region个数(0.94版之后)

让天下没有难学的技术

## 第4章 HBase API

## 4.1 环境准备

新建项目后在 pom.xml 中添加依赖:

### 4.2 HBaseAPI

## 4.2.1 获取 Configuration 对象

```
public static Configuration conf;
static{
    //使用 HBaseConfiguration 的单例方法实例化
    conf = HBaseConfiguration.create();
    conf.set("hbase.zookeeper.quorum", "192.166.9.102");
    conf.set("hbase.zookeeper.property.clientPort", "2181");
}
```

## 4.2.2 判断表是否存在

```
public static boolean isTableExist(String tableName) throws MasterNotRunningException,
ZooKeeperConnectionException, IOException{
    //在 HBase 中管理、访问表需要先创建 HBaseAdmin 对象
```



### 4.2.3 创建表

```
public static void createTable(String
                                          tableName,
                                                      String...
columnFamily) throws
MasterNotRunningException,
                                   ZooKeeperConnectionException,
IOException{
   HBaseAdmin admin = new HBaseAdmin(conf);
   //判断表是否存在
   if(isTableExist(tableName)){
      System.out.println("表" + tableName + "已存在");
      //System.exit(0);
   }else{
      //创建表属性对象,表名需要转字节
      HTableDescriptor
                               descriptor
                                                            new
HTableDescriptor(TableName.valueOf(tableName));
      //创建多个列族
      for(String cf : columnFamily) {
         descriptor.addFamily(new HColumnDescriptor(cf));
      //根据对表的配置, 创建表
      admin.createTable(descriptor);
      System.out.println("表" + tableName + "创建成功!");
```

### 4.2.4 删除表

```
public static void dropTable(String tableName) throws
MasterNotRunningException,
ZooKeeperConnectionException, IOException{
    HBaseAdmin admin = new HBaseAdmin(conf);
    if(isTableExist(tableName)){
        admin.disableTable(tableName);
        admin.deleteTable(tableName);
        System.out.println("表" + tableName + "删除成功!");
    }else{
        System.out.println("表" + tableName + "不存在!");
    }
}
```

## 4.2.5 向表中插入数据

```
public static void addRowData(String tableName, String rowKey, String columnFamily, String column, String value) throws IOException{
    //创建 HTable 对象
    HTable hTable = new HTable(conf, tableName);
    //向表中插入数据
    Put put = new Put(Bytes.toBytes(rowKey));
    //向 Put 对象中组装数据
```



```
put.add(Bytes.toBytes(columnFamily),
Bytes.toBytes(value));
hTable.put(put);
hTable.close();
System.out.println("插入数据成功");
}
```

## 4.2.6 删除多行数据

```
public static void deleteMultiRow(String tableName, String... rows)
throws IOException{
   HTable hTable = new HTable(conf, tableName);
   List<Delete> deleteList = new ArrayList<Delete>();
   for(String row : rows) {
        Delete delete = new Delete(Bytes.toBytes(row));
        deleteList.add(delete);
   }
   hTable.delete(deleteList);
   hTable.close();
}
```

## 4.2.7 获取所有数据

```
public static void getAllRows(String tableName) throws IOException{
   HTable hTable = new HTable(conf, tableName);
   //得到用于扫描 region 的对象
   Scan scan = new Scan();
   //使用 HTable 得到 resultcanner 实现类的对象
   ResultScanner resultScanner = hTable.getScanner(scan);
   for(Result result : resultScanner) {
      Cell[] cells = result.rawCells();
      for(Cell cell : cells) {
          //得到 rowkey
          System.out.println("
                                             键
                                                      . "
                                行
Bytes.toString(CellUtil.cloneRow(cell)));
          //得到列族
         System.out.println("
                                             族
Bytes.toString(CellUtil.cloneFamily(cell)));
         System.out.println("
                                       列
Bytes.toString(CellUtil.cloneQualifier(cell)));
         System.out.println("
Bytes.toString(CellUtil.cloneValue(cell)));
```

## 4.2.8 获取某一行数据



```
Bytes.toString(result.getRow()));
        System.out.println(" 列 族 " +
Bytes.toString(CellUtil.cloneFamily(cell)));
        System.out.println(" 列 :" +
Bytes.toString(CellUtil.cloneQualifier(cell)));
        System.out.println(" 值 :" +
Bytes.toString(CellUtil.cloneValue(cell)));
        System.out.println("时间戳:" + cell.getTimestamp());
        }
}
```

## 4.2.9 获取某一行指定"列族:列"的数据

```
public static void getRowQualifier(String tableName, String rowKey,
String family, String
qualifier) throws IOException{
   HTable table = new HTable(conf, tableName);
   Get get = new Get(Bytes.toBytes(rowKey));
   get.addColumn(Bytes.toBytes(family),
Bytes.toBytes(qualifier));
   Result result = table.get(get);
   for(Cell cell : result.rawCells()){
      System.out.println("
Bytes.toString(result.getRow()));
                                            族
      System.out.println("
                                   列
Bytes.toString(CellUtil.cloneFamily(cell)));
      System.out.println("
Bytes.toString(CellUtil.cloneQualifier(cell)));
      System.out.println("
Bytes.toString(CellUtil.cloneValue(cell)));
```

## 4.3 MapReduce

通过 HBase 的相关 JavaAPI,我们可以实现伴随 HBase 操作的 MapReduce 过程,比如使用 MapReduce 将数据从本地文件系统导入到 HBase 的表中,比如我们从 HBase 中读取一些原始数据后使用 MapReduce 做数据分析。

## 4.3.1 官方 HBase-MapReduce

#### 1. 查看 HBase 的 MapReduce 任务的执行

\$ bin/hbase mapredcp

#### 2. 环境变量的导入

(1) 执行环境变量的导入(临时生效,在命令行执行下述操作)

```
$ export HBASE_HOME=/opt/module/hbase
$ export HADOOP_HOME=/opt/module/hadoop-2.7.2
$ export HADOOP_CLASSPATH=`${HBASE_HOME}/bin/hbase_mapredcp`
```

### (2) 永久生效: 在/etc/profile 配置

```
export HBASE_HOME=/opt/module/hbase
export HADOOP HOME=/opt/module/hadoop-2.7.2
```



并在 hadoop-env.sh 中配置: (注意: 在 for 循环之后配) export HADOOP\_CLASSPATH=\$HADOOP\_CLASSPATH:/opt/module/hbase/lib/\*

- 3. 运行官方的 MapReduce 任务
- -- 案例一: 统计 Student 表中有多少行数据

\$ /opt/module/hadoop-2.7.2/bin/yarn jar lib/hbase-server-1.3.1.jar rowcounter student

- -- 案例二: 使用 MapReduce 将本地数据导入到 HBase
- 1) 在本地创建一个 tsv 格式的文件: fruit.tsv

```
1001 Apple Red
1002 Pear Yellow
1003 Pineapple Yellow
```

2) 创建 Hbase 表

```
Hbase(main):001:0> create 'fruit','info'
```

3) 在 HDFS 中创建 input fruit 文件夹并上传 fruit.tsv 文件

```
$ /opt/module/hadoop-2.7.2/bin/hdfs dfs -mkdir /input_fruit/
$ /opt/module/hadoop-2.7.2/bin/hdfs dfs -put fruit.tsv
/input_fruit/
```

4) 执行 MapReduce 到 HBase 的 fruit 表中

```
$ /opt/module/hadoop-2.7.2/bin/yarn jar lib/hbase-server-1.3.1.jar
importtsv \
-Dimporttsv.columns=HBASE_ROW_KEY,info:name,info:color fruit \
hdfs://hadoop102:9000/input_fruit
```

5) 使用 scan 命令查看导入后的结果

```
Hbase(main):001:0> scan 'fruit'
```

## 4.3.2 自定义 HBase-MapReduce1

目标:将 fruit 表中的一部分数据,通过 MR 迁入到 fruit mr 表中。

分步实现:

### 1. 构建 ReadFruitMapper 类, 用于读取 fruit 表中的数据

```
package com.atguigu;
import java.io.IOException;
import org.apache.hadoop.hbase.Cell;
import org.apache.hadoop.hbase.CellUtil;
import org.apache.hadoop.hbase.client.Put;
import org.apache.hadoop.hbase.client.Result;
import org.apache.hadoop.hbase.io.ImmutableBytesWritable;
import org.apache.hadoop.hbase.mapreduce.TableMapper;
import org.apache.hadoop.hbase.util.Bytes;

public class ReadFruitMapper extends
TableMapper<ImmutableBytesWritable, Put> {
    @Override
```



```
protected void map(ImmutableBytesWritable key, Result value,
Context context)
   throws IOException, InterruptedException {
   //将 fruit 的 name 和 color 提取出来,相当于将每一行数据读取出来放入到 Put
对象中。
      Put put = new Put(key.get());
      //遍历添加 column 行
      for(Cell cell: value.rawCells()) {
         //添加/克隆列族:info
   if("info".equals(Bytes.toString(CellUtil.cloneFamily(cell)))){
            //添加/克隆列: name
   if("name".equals(Bytes.toString(CellUtil.cloneQualifier(cell))
)){
                //将该列 cell 加入到 put 对象中
                put.add(cell);
                //添加/克隆列:color
            }else
if("color".equals(Bytes.toString(CellUtil.cloneQualifier(cell)))))
                //向该列 cell 加入到 put 对象中
                put.add(cell);
            }
         }
      //将从 fruit 读取到的每行数据写入到 context 中作为 map 的输出
      context.write(key, put);
   }
```

2. 构建 WriteFruitMRReducer 类, 用于将读取到的 fruit 表中的数据写入到 fruit\_mr 表中

```
package com.atguigu.Hbase_mr;
import java.io.IOException;
import org.apache.hadoop.Hbase.client.Put;
import org.apache.hadoop.Hbase.io.ImmutableBytesWritable;
import org.apache.hadoop.Hbase.mapreduce.TableReducer;
import org.apache.hadoop.io.NullWritable;
                              WriteFruitMRReducer
public
               class
                                                           extends
TableReducer<ImmutableBytesWritable, Put, NullWritable> {
   @Override
   protected void reduce(ImmutableBytesWritable key, Iterable<Put>
values, Context context)
   throws IOException, InterruptedException {
      //读出来的每一行数据写入到 fruit mr 表中
      for(Put put: values) {
          context.write(NullWritable.get(), put);
      }
   }
```

3. 构建 Fruit2FruitMRRunner extends Configured implements Tool 用于组装运行 Job



#### 任务

```
//组装 Job
   public int run(String[] args) throws Exception {
      //得到 Configuration
      Configuration conf = this.getConf();
      //创建 Job 任务
      Job
                    job
                                            Job.getInstance(conf,
this.getClass().getSimpleName());
      job.setJarByClass(Fruit2FruitMRRunner.class);
      //配置 Job
      Scan scan = new Scan();
      scan.setCacheBlocks(false);
      scan.setCaching(500);
      //设置 Mapper,注意导入的是 mapreduce 包下的,不是 mapred 包下的,后者
是老版本
      TableMapReduceUtil.initTableMapperJob(
      "fruit", //数据源的表名
      scan, //scan 扫描控制器
      ReadFruitMapper.class,//设置 Mapper 类
      ImmutableBytesWritable.class,//设置 Mapper 输出 key 类型
      Put.class, //设置 Mapper 输出 value 值类型
      job//设置给哪个 JOB
      );
      //设置 Reducer
      TableMapReduceUtil.initTableReducerJob("fruit mr",
WriteFruitMRReducer.class, job);
      //设置 Reduce 数量,最少1个
      job.setNumReduceTasks(1);
      boolean isSuccess = job.waitForCompletion(true);
      if(!isSuccess){
          throw new IOException ("Job running with error");
      return isSuccess ? 0 : 1;
```

#### 4. 主函数中调用运行该 Job 任务

```
public static void main( String[] args ) throws Exception{
Configuration conf = HbaseConfiguration.create();
int status = ToolRunner.run(conf, new Fruit2FruitMRRunner(), args);
System.exit(status);
}
```

#### 5. 打包运行任务

```
$ /opt/module/hadoop-2.7.2/bin/yarn jar ~/softwares/jars/Hbase-
0.0.1-SNAPSHOT.jar
com.z.Hbase.mr1.Fruit2FruitMRRunner
```

提示: 运行任务前,如果待数据导入的表不存在,则需要提前创建。

提示: maven 打包命令: -P local clean package 或-P dev clean package install (将第三方 jar 包一同打包,需要插件: maven-shade-plugin)

## 4.3.3 自定义 Hbase-MapReduce2



目标:实现将 HDFS 中的数据写入到 Hbase 表中。

分步实现:

1. 构建 ReadFruitFromHDFSMapper 于读取 HDFS 中的文件数据

```
package com.atguigu;
import java.io.IOException;
import org.apache.hadoop.hbase.client.Put;
import org.apache.hadoop.hbase.io.ImmutableBytesWritable;
import org.apache.hadoop.hbase.util.Bytes;
import org.apache.hadoop.io.LongWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Mapper;
public class ReadFruitFromHDFSMapper extends Mapper<LongWritable,
Text, ImmutableBytesWritable, Put> {
   @Override
   protected void map(LongWritable key, Text value, Context
context) throws IOException, InterruptedException {
      //从 HDFS 中读取的数据
      String lineValue = value.toString();
      //读取出来的每行数据使用\t 进行分割,存于 String 数组
      String[] values = lineValue.split("\t");
      //根据数据中值的含义取值
      String rowKey = values[0];
      String name = values[1];
      String color = values[2];
      //初始化 rowKey
      ImmutableBytesWritable rowKeyWritable
ImmutableBytesWritable(Bytes.toBytes(rowKey));
      //初始化 put 对象
      Put put = new Put(Bytes.toBytes(rowKey));
      //参数分别:列族、列、值
      put.add(Bytes.toBytes("info"),
                                         Bytes.toBytes("name"),
Bytes.toBytes(name));
      put.add(Bytes.toBytes("info"), Bytes.toBytes("color"),
Bytes.toBytes(color));
      context.write(rowKeyWritable, put);
```

#### 2. 构建 WriteFruitMRFromTxtReducer 类

```
package com.z.Hbase.mr2;
import java.io.IOException;
import org.apache.hadoop.hbase.client.Put;
import org.apache.hadoop.hbase.io.ImmutableBytesWritable;
import org.apache.hadoop.hbase.mapreduce.TableReducer;
import org.apache.hadoop.io.NullWritable;
```



```
public class WriteFruitMRFromTxtReducer extends
TableReducer<ImmutableBytesWritable, Put, NullWritable> {
    @Override
    protected void reduce(ImmutableBytesWritable key, Iterable<Put>
values, Context context) throws IOException, InterruptedException
{
    //读出来的每一行数据写入到 fruit_hdfs 表中
    for(Put put: values) {
        context.write(NullWritable.get(), put);
    }
}
```

#### 3. 创建 Txt2FruitRunner 组装 Job

```
public int run(String[] args) throws Exception {
//得到 Configuration
Configuration conf = this.getConf();
//创建 Job 任务
Job job = Job.getInstance(conf, this.getClass().getSimpleName());
job.setJarByClass(Txt2FruitRunner.class);
                     inPath
Path("hdfs://hadoop102:9000/input fruit/fruit.tsv");
FileInputFormat.addInputPath(job, inPath);
//设置 Mapper
job.setMapperClass(ReadFruitFromHDFSMapper.class);
job.setMapOutputKeyClass(ImmutableBytesWritable.class);
job.setMapOutputValueClass(Put.class);
//设置 Reducer
TableMapReduceUtil.initTableReducerJob("fruit mr",
WriteFruitMRFromTxtReducer.class, job);
//设置 Reduce 数量,最少1个
job.setNumReduceTasks(1);
boolean isSuccess = job.waitForCompletion(true);
if(!isSuccess){
throw new IOException ("Job running with error");
return isSuccess ? 0 : 1;
```

#### 4. 调用执行 Job

```
public static void main(String[] args) throws Exception {
          Configuration conf = HBaseConfiguration.create();
          int status = ToolRunner.run(conf, new Txt2FruitRunner(),
          args);
          System.exit(status);
}
```

#### 5. 打包运行

\$ /opt/module/hadoop-2.7.2/bin/yarn jar hbase-0.0.1-SNAPSHOT.jar com.atguigu.hbase.mr2.Txt2FruitRunner



提示: 运行任务前,如果待数据导入的表不存在,则需要提前创建之。

提示: maven 打包命令: -P local clean package 或-P dev clean package install (将第三方 jar 包一同打包,需要插件: maven-shade-plugin)

## 4.4 与 Hive 的集成

## 4.4.1 HBase 与 Hive 的对比

#### 1. Hive

(1) 数据仓库

Hive 的本质其实就相当于将 HDFS 中已经存储的文件在 Mysql 中做了一个双射关系,以方便使用 HQL 去管理查询。

(2) 用于数据分析、清洗

Hive 适用于离线的数据分析和清洗,延迟较高。

(3) 基于 HDFS、MapReduce

Hive 存储的数据依旧在 DataNode 上,编写的 HQL 语句终将是转换为 MapReduce 代码执行。

#### 2. HBase

(1) 数据库

是一种面向列族存储的非关系型数据库。

(2) 用于存储结构化和非结构化的数据

适用于单表非关系型数据的存储,不适合做关联查询,类似 JOIN 等操作。

(3) 基于 HDFS

数据持久化存储的体现形式是 HFile, 存放于 DataNode 中, 被 ResionServer 以 region 的形式进行管理。

(4) 延迟较低,接入在线业务使用

面对大量的企业数据,HBase 可以直线单表大量数据的存储,同时提供了高效的数据访问速度。

## 4.4.2 HBase 与 Hive 集成使用

尖叫提示: HBase 与 Hive 的集成在最新的两个版本中无法兼容。所以,我们只能含着泪勇敢的重新编译: hive-hbase-handler-1.2.2.jar!! 好气!!

#### 环境准备

因为我们后续可能会在操作 Hive 的同时对 HBase 也会产生影响,所以 Hive 需要持有操作 HBase 的 Jar, 那么接下来拷贝 Hive 所依赖的 Jar 包(或者使用软连接的形式)。



同时在 hive-site.xml 中修改 zookeeper 的属性,如下:

#### 1. 案例一

目标: 建立 Hive 表, 关联 HBase 表, 插入数据到 Hive 表的同时能够影响 HBase 表。

#### 分步实现:

(1) 在 Hive 中创建表同时关联 HBase

```
CREATE TABLE hive_hbase_emp_table(
empno int,
ename string,
job string,
mgr int,
hiredate string,
sal double,
comm double,
deptno int)
STORED BY 'org.apache.hadoop.hive.hbase.HBaseStorageHandler'
WITH SERDEPROPERTIES ("hbase.columns.mapping" =
":key,info:ename,info:job,info:mgr,info:hiredate,info:sal,info:co
mm,info:deptno")
TBLPROPERTIES ("hbase.table.name" = "hbase_emp_table");
```

提示: 完成之后,可以分别进入 Hive 和 HBase 查看,都生成了对应的表

(2) 在 Hive 中创建临时中间表,用于 load 文件中的数据

提示: 不能将数据直接 load 进 Hive 所关联 HBase 的那张表中

```
CREATE TABLE emp(
empno int,
ename string,
job string,
mgr int,
```



```
hiredate string,
sal double,
comm double,
deptno int)
row format delimited fields terminated by '\t';
```

(3) 向 Hive 中间表中 load 数据

hive> load data local inpath '/home/admin/softwares/data/emp.txt'
into table emp;

(4) 通过 insert 命令将中间表中的数据导入到 Hive 关联 Hbase 的那张表中

hive> insert into table hive hbase emp table select \* from emp;

(5) 查看 Hive 以及关联的 HBase 表中是否已经成功的同步插入了数据

#### Hive:

```
hive> select * from hive_hbase_emp_table;
HBase:
```

Hbase> scan 'hbase emp table'

#### 2. 案例二

**目标:** 在 HBase 中已经存储了某一张表 hbase\_emp\_table,然后在 Hive 中创建一个外部表来 关联 HBase 中的 hbase\_emp\_table 这张表,使之可以借助 Hive 来分析 HBase 这张表中的数据。

注: 该案例 2 紧跟案例 1 的脚步, 所以完成此案例前, 请先完成案例 1。

#### 分步实现:

(1) 在 Hive 中创建外部表

```
CREATE EXTERNAL TABLE relevance_hbase_emp(
empno int,
ename string,
job string,
mgr int,
hiredate string,
sal double,
comm double,
deptno int)
STORED BY
'org.apache.hadoop.hive.hbase.HBaseStorageHandler'
WITH SERDEPROPERTIES ("hbase.columns.mapping" =
":key,info:ename,info:job,info:mgr,info:hiredate,info:sal,info:co
mm,info:deptno")
TBLPROPERTIES ("hbase.table.name" = "hbase_emp_table");
```

(2) 关联后就可以使用 Hive 函数进行一些分析操作了

hive (default) > select \* from relevance hbase emp;

## 第5章 HBase 优化

### 5.1 高可用

在 HBase 中 HMaster 负责监控 HRegionServer 的生命周期,均衡 RegionServer 的负载,如果 HMaster 挂掉了,那么整个 HBase 集群将陷入不健康的状态,并且此时的工作状态并不会维持太久。所以 HBase 支持对 HMaster 的高可用配置。

#### 1. 关闭 HBase 集群(如果没有开启则跳过此步)

[atguigu@hadoop102 hbase]\$ bin/stop-hbase.sh



#### 2. 在 conf 目录下创建 backup-masters 文件

[atguigu@hadoop102 hbase]\$ touch conf/backup-masters

#### 3. 在 backup-masters 文件中配置高可用 HMaster 节点

[atguigu@hadoop102 hbase] \$ echo hadoop103 > conf/backup-masters

#### 4. 将整个 conf 目录 scp 到其他节点

•				
[atguigu@hadoop102	hbase]\$	scp	-r	conf/
hadoop103:/opt/module/	hbase/			
[atguigu@hadoop102	hbase]\$	scp	-r	conf/
hadoop104:/opt/module/	hbase/			

#### 5. 打开页面测试查看

http://hadooo102:16010

### 5.2 预分区

每一个 region 维护着 StartRow 与 EndRow,如果加入的数据符合某个 Region 维护的 RowKey 范围,则该数据交给这个 Region 维护。那么依照这个原则,我们可以将数据所要投放的分区提前大致的规划好,以提高 HBase 性能。

### 1. 手动设定预分区

```
Hbase> create 'staff1','info','partition1',SPLITS =>
['1000','2000','3000','4000']
```

#### 2. 生成 16 进制序列预分区

create 'staff2','info','partition2',{NUMREGIONS => 15, SPLITALGO =>
'HexStringSplit'}

#### 3. 按照文件中设置的规则预分区

创建 splits.txt 文件内容如下:

aaaa

bbbb

cccc

dddd

然后执行:

create 'staff3','partition3',SPLITS FILE => 'splits.txt'

#### 4. 使用 JavaAPI 创建预分区

```
//自定义算法,产生一系列 hash 散列值存储在二维数组中byte[][] splitKeys = 某个散列值函数 //创建 HbaseAdmin 实例 HBaseAdmin hAdmin = new HBaseAdmin(HbaseConfiguration.create()); //创建 HTableDescriptor 实例 HTableDescriptor tableDesc = new HTableDescriptor(tableName); //通过 HTableDescriptor 实例和散列值二维数组创建带有预分区的 Hbase 表hAdmin.createTable(tableDesc, splitKeys);
```

## 5.3 RowKey 设计

一条数据的唯一标识就是 RowKey,那么这条数据存储于哪个分区,取决于 RowKey 处于哪个一个预分区的区间内,设计 RowKey 的主要目的 ,就是让数据均匀的分布于所有的 region 中,在一定程度上防止数据倾斜。接下来我们就谈一谈 RowKey 常用的设计方案。

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



### 1. 生成随机数、hash、散列值

比如: 后 变 成 原 本 rowKev 为 1001 的 SHA1 dd01903921ea24941c26a48f2cec24e0bb0e8cc7 变 成 rowKey 为 3001 的 SHA1 后 49042c54de64a1e9bf0b33e00245660ef92dc7bd 变 rowKey 为 5001 的 SHA1 后 成 7b61dec07e02c188790670af43e717f0f46e8913 在做此操作之前,一般我们会选择从数据集中抽取样本,来决定什么样的 rowKey 来 Hash 后作为每个分区的临界值。

#### 2. 字符串反转

20170524000001 转成 10000042507102 20170524000002 转成 20000042507102

这样也可以在一定程度上散列逐步 put 进来的数据。

#### 3. 字符串拼接

20170524000001\_a12e 20170524000001 93i7

## 5.4 内存优化

HBase 操作过程中需要大量的内存开销,毕竟 Table 是可以缓存在内存中的,一般会分配整个可用内存的 70%给 HBase 的 Java 堆。但是不建议分配非常大的堆内存,因为 GC 过程持续太久会导致 RegionServer 处于长期不可用状态,一般 16~48G 内存就可以了,如果因为框架占用内存过高导致系统内存不足,框架一样会被系统服务拖死。

## 5.5 基础优化

#### 1. 允许在 HDFS 的文件中追加内容

hdfs-site.xml, hbase-site.xml

属性: dfs.support.append

解释: 开启 HDFS 追加同步,可以优秀的配合 HBase 的数据同步和持久化。默认值为 true。

#### 2. 优化 DataNode 允许的最大文件打开数

hdfs-site.xml

属性: dfs.datanode.max.transfer.threads

解释: HBase 一般都会同一时间操作大量的文件,根据集群的数量和规模以及数据动作,设置为4096或者更高。默认值: 4096

#### 3. 优化延迟高的数据操作的等待时间

hdfs-site xml

属性: dfs.image.transfer.timeout

解释:如果对于某一次数据操作来讲,延迟非常高,socket 需要等待更长的时间,建议把该值设置为更大的值(默认 60000 毫秒),以确保 socket 不会被 timeout 掉。

#### 4. 优化数据的写入效率

mapred-site.xml

属性:



mapreduce.map.output.compress

mapreduce.map.output.compress.codec

解释: 开启这两个数据可以大大提高文件的写入效率,减少写入时间。第一个属性值修改为true,第二个属性值修改为: org.apache.hadoop.io.compress.GzipCodec或者其他压缩方式。

#### 5. 设置 RPC 监听数量

hbase-site.xml

属性: Hbase.regionserver.handler.count

解释:默认值为 30,用于指定 RPC 监听的数量,可以根据客户端的请求数进行调整,读写请求较多时,增加此值。

### 6. 优化 HStore 文件大小

hbase-site.xml

属性: hbase.hregion.max.filesize

解释:默认值 10737418240 (10GB),如果需要运行 HBase 的 MR 任务,可以减小此值,因为一个 region 对应一个 map 任务,如果单个 region 过大,会导致 map 任务执行时间过长。该值的意思就是,如果 HFile 的大小达到这个数值,则这个 region 会被切分为两个 Hfile。

#### 7. 优化 HBase 客户端缓存

hbase-site.xml

属性: hbase.client.write.buffer

解释:用于指定 Hbase 客户端缓存,增大该值可以减少 RPC 调用次数,但是会消耗更多内存,反之则反之。一般我们需要设定一定的缓存大小,以达到减少 RPC 次数的目的。

#### 8. 指定 scan.next 扫描 HBase 所获取的行数

hbase-site.xml

属性: hbase.client.scanner.caching

解释:用于指定 scan.next 方法获取的默认行数,值越大,消耗内存越大。

#### 9. flush、compact、split 机制

当 MemStore 达到阈值,将 Memstore 中的数据 Flush 进 Storefile; compact 机制则是把 flush 出来的小文件合并成大的 Storefile 文件。split 则是当 Region 达到阈值,会把过大的 Region 一分为二。

#### 涉及属性:

即: 128M 就是 Memstore 的默认阈值

hbase.hregion.memstore.flush.size: 134217728

即:这个参数的作用是当单个 HRegion 内所有的 Memstore 大小总和超过指定值时,flush 该 HRegion 的所有 memstore。RegionServer 的 flush 是通过将请求添加一个队列,模拟生产消费模型来异步处理的。那这里就有一个问题,当队列来不及消费,产生大量积压请求时,可能会导致内存陡增,最坏的情况是触发 OOM。

hbase.regionserver.global.memstore.upperLimit: 0.4 hbase.regionserver.global.memstore.lowerLimit: 0.38

即: 当 MemStore 使用内存总量达到 hbase regionserver global memstore upperLimit 指定值时,

更多 Java –大数据 –前端 –python 人工智能资料下载,可百度访问:尚硅谷官网



将会有多个 MemStores flush 到文件中,MemStore flush 顺序是按照大小降序执行的,直到 刷新到 MemStore 使用内存略小于 lowerLimit

## 第6章 HBase 实战之谷粒微博

## 6.1 需求分析

- 1) 微博内容的浏览,数据库表设计
- 2) 用户社交体现: 关注用户, 取关用户
- 3) 拉取关注的人的微博内容

## 6.2 代码实现

### 6.2.1 代码设计总览:

- 1) 创建命名空间以及表名的定义
- 2) 创建微博内容表
- 3) 创建用户关系表
- 4) 创建用户微博内容接收邮件表
- 5) 发布微博内容
- 6) 添加关注用户
- 7) 移除(取关) 用户
- 8) 获取关注的人的微博内容
- 9) 测试

## 6.2.2 创建命名空间以及表名的定义

```
//获取配置 conf
private Configuration conf = HbaseConfiguration.create();
//微博内容表的表名
                               byte[]
           static
                                           TABLE CONTENT
Bytes.toBytes("weibo:content");
//用户关系表的表名
private static
                     final
                              byte[]
                                         TABLE RELATIONS
Bytes.toBytes("weibo:relations");
//微博收件箱表的表名
private static final byte[] TABLE RECEIVE CONTENT EMAIL
Bytes.toBytes("weibo:receive content email");
public void initNamespace() {
   HbaseAdmin admin = null;
   try {
      admin = new HbaseAdmin(conf);
      //命名空间类似于关系型数据库中的 schema, 可以想象成文件夹
      NamespaceDescriptor weibo = NamespaceDescriptor
            .create("weibo")
            .addConfiguration("creator", "Jinji")
            .addConfiguration("create time",
System.currentTimeMillis() + "")
            .build();
```



```
admin.createNamespace(weibo);
} catch (MasterNotRunningException e) {
    e.printStackTrace();
} catch (ZooKeeperConnectionException e) {
    e.printStackTrace();
} catch (IOException e) {
    e.printStackTrace();
} finally{
    if(null != admin) {
        try {
            admin.close();
        } catch (IOException e) {
            e.printStackTrace();
        }
      }
}
```

## 6.2.3 创建微博内容表

#### 表结构:

方法名	creatTableeContent
Table Name	weibo:content
RowKey	用户 ID_时间戳
ColumnFamily	info
ColumnLabel	标题,内容,图片
Version	1个版本

#### 代码:

```
/**
* 创建微博内容表
* Table Name:weibo:content
* RowKey:用户 ID 时间戳
* ColumnFamily:info
* ColumnLabel:标题 内容
                             图片 URL
 * Version:1 个版本
public void createTableContent() {
   HbaseAdmin admin = null;
   try {
      admin = new HbaseAdmin(conf);
      //创建表表述
      HTableDescriptor
                                content
                                                             new
HTableDescriptor(TableName.valueOf(TABLE CONTENT));
      //创建列族描述
      HColumnDescriptor
                                 info
                                                             new
HColumnDescriptor(Bytes.toBytes("info"));
      //设置块缓存
      info.setBlockCacheEnabled(true);
      //设置块缓存大小
      info.setBlocksize(2097152);
      //设置压缩方式
//
         info.setCompressionType(Algorithm.SNAPPY);
      //设置版本确界
      info.setMaxVersions(1);
```



```
info.setMinVersions(1);
   content.addFamily(info);
   admin.createTable(content);
} catch (MasterNotRunningException e) {
   e.printStackTrace();
} catch (ZooKeeperConnectionException e) {
   e.printStackTrace();
} catch (IOException e) {
   e.printStackTrace();
}finally{
   if(null != admin) {
      try {
          admin.close();
       } catch (IOException e) {
          e.printStackTrace();
   }
```

### 6.2.4 创建用户关系表

#### 表结构:

方法名	createTableRelations
Table Name	weibo:relations
RowKey	用户 ID
ColumnFamily	attends、 fans
ColumnLabel	关注用户 ID,粉丝用户 ID
ColumnValue	用户 ID
Version	1个版本

#### 代码:

```
/**
* 用户关系表
* Table Name:weibo:relations0
* RowKey:用户 ID
* ColumnFamily:attends, fans
* ColumnLabel:关注用户ID, 粉丝用户ID
 * ColumnValue:用户 ID
 * Version: 1个版本
*/
public void createTableRelations() {
   HbaseAdmin admin = null;
   try {
      admin = new HbaseAdmin(conf);
      HTableDescriptor relations
                                                             new
HTableDescriptor(TableName.valueOf(TABLE RELATIONS));
      //关注的人的列族
      HColumnDescriptor
                                attends
                                                             new
HColumnDescriptor(Bytes.toBytes("attends"));
      //设置块缓存
      attends.setBlockCacheEnabled(true);
```



```
//设置块缓存大小
      attends.setBlocksize(2097152);
      //设置压缩方式
          info.setCompressionType(Algorithm.SNAPPY);
      //设置版本确界
      attends.setMaxVersions(1);
      attends.setMinVersions(1);
      //粉丝列族
      HColumnDescriptor
                                                               new
HColumnDescriptor(Bytes.toBytes("fans"));
      fans.setBlockCacheEnabled(true);
      fans.setBlocksize(2097152);
      fans.setMaxVersions(1);
      fans.setMinVersions(1);
      relations.addFamily(attends);
      relations.addFamily(fans);
      admin.createTable(relations);
   } catch (MasterNotRunningException e) {
      e.printStackTrace();
   } catch (ZooKeeperConnectionException e) {
      e.printStackTrace();
   } catch (IOException e) {
      e.printStackTrace();
   }finally{
      if(null != admin) {
          try {
             admin.close();
          } catch (IOException e) {
             e.printStackTrace();
      }
   }
```

## 6.2.5 创建微博收件箱表

#### 表结构:

*** T T T T T T T T T T T T T T T T T T		
方法名	createTableReceiveContentEmails	
Table Name	weibo:receive_content_email	
RowKey	用户 ID	
ColumnFamily	info	
ColumnLabel	用户 ID	
ColumnValue	取微博内容的 RowKey	
Version	1000	

#### 代码:

```
/**

* 创建微博收件箱表

* Table Name: weibo:receive_content_email

* RowKey:用户 ID

* ColumnFamily:info
```



```
* ColumnLabel:用户 ID-发布微博的人的用户 ID
* ColumnValue: 关注的人的微博的 RowKey
* Version:1000
*/
public void createTableReceiveContentEmail() {
   HbaseAdmin admin = null;
   try {
      admin = new HbaseAdmin(conf);
      HTableDescriptor receive content email
HTableDescriptor(TableName.valueOf(TABLE RECEIVE CONTENT EMAIL));
      HColumnDescriptor
                                   info
                                                               new
HColumnDescriptor(Bytes.toBytes("info"));
      info.setBlockCacheEnabled(true);
      info.setBlocksize(2097152);
      info.setMaxVersions(1000);
      info.setMinVersions(1000);
      receive content email.addFamily(info);;
      admin.createTable(receive content email);
   } catch (MasterNotRunningException e) {
      e.printStackTrace();
   } catch (ZooKeeperConnectionException e) {
      e.printStackTrace();
   } catch (IOException e) {
      e.printStackTrace();
   }finally{
      if(null != admin) {
          try {
             admin.close();
          } catch (IOException e) {
             e.printStackTrace();
      }
   }
```

## 6.2.6 发布微博内容

- a、微博内容表中添加 1 条数据
- b、微博收件箱表对所有粉丝用户添加数据

#### 代码: Message.java

```
package com.atguigu.weibo;

public class Message {
    private String uid;
    private String timestamp;
    private String content;

public String getUid() {
        return uid;
    }
    public void setUid(String uid) {
        this.uid = uid;
    }
    public String getTimestamp() {
        return timestamp;
```



```
public void setTimestamp(String timestamp) {
    this.timestamp = timestamp;
}
public String getContent() {
    return content;
}
public void setContent(String content) {
    this.content = content;
}
@Override
public String toString() {
    return "Message [uid=" + uid + ", timestamp=" + timestamp + ", content=" + content + "]";
}
```

#### 代码: public void publishContent(String uid, String content)

```
/**
* 发布微博
* a、微博内容表中数据+1
 * b、向微博收件箱表中加入微博的 Rowkey
*/
public void publishContent(String uid, String content) {
   HConnection connection = null;
   try {
      connection = HConnectionManager.createConnection(conf);
      //a、微博内容表中添加 1 条数据,首先获取微博内容表描述
      HTableInterface
connection.getTable(TableName.valueOf(TABLE CONTENT));
      //组装 Rowkey
      long timestamp = System.currentTimeMillis();
      String rowKey = uid + " " + timestamp;
      Put put = new Put(Bytes.toBytes(rowKey));
      put.add(Bytes.toBytes("info"), Bytes.toBytes("content"),
timestamp, Bytes.toBytes(content));
      contentTBL.put(put);
      //b、向微博收件箱表中加入发布的 Rowkey
      //b.1、查询用户关系表,得到当前用户有哪些粉丝
      HTableInterface
                                   relationsTBL
connection.getTable(TableName.valueOf(TABLE RELATIONS));
      //b.2、取出目标数据
      Get get = new Get(Bytes.toBytes(uid));
      get.addFamily(Bytes.toBytes("fans"));
      Result result = relationsTBL.get(get);
      List<byte[]> fans = new ArrayList<byte[]>();
      //遍历取出当前发布微博的用户的所有粉丝数据
      for(Cell cell : result.rawCells()){
         fans.add(CellUtil.cloneQualifier(cell));
      //如果该用户没有粉丝,则直接 return
      if(fans.size() <= 0) return;</pre>
```



```
//开始操作收件箱表
      HTableInterface
                                        recTBI.
connection.getTable(TableName.valueOf(TABLE RECEIVE CONTENT EMAIL
));
      List<Put> puts = new ArrayList<Put>();
      for(byte[] fan : fans) {
          Put fanPut = new Put(fan);
         fanPut.add(Bytes.toBytes("info"), Bytes.toBytes(uid),
timestamp, Bytes.toBytes(rowKey));
         puts.add(fanPut);
      recTBL.put(puts);
   } catch (IOException e) {
      e.printStackTrace();
   }finally{
      if(null != connection) {
          try {
             connection.close();
          } catch (IOException e) {
             e.printStackTrace();
      }
   }
```

## 6.2.7 添加关注用户

- a、在微博用户关系表中,对当前主动操作的用户添加新关注的好友
- b、在微博用户关系表中,对被关注的用户添加新的粉丝
- c、微博收件箱表中添加所关注的用户发布的微博

#### 代码实现: public void addAttends(String uid, String... attends)

```
* 关注用户逻辑
* a、在微博用户关系表中,对当前主动操作的用户添加新的关注的好友
* b、在微博用户关系表中,对被关注的用户添加粉丝(当前操作的用户)
* c、当前操作用户的微博收件箱添加所关注的用户发布的微博 rowkey
public void addAttends(String uid, String... attends) {
   if(attends == null || attends.length <= 0 || uid == null ||
uid.length() <= 0){</pre>
     return;
  HConnection connection = null;
   try {
      connection = HConnectionManager.createConnection(conf);
      //用户关系表操作对象(连接到用户关系表)
      HTableInterface
                                 relationsTBL
connection.getTable(TableName.valueOf(TABLE RELATIONS));
      List<Put> puts = new ArrayList<Put>();
      //a、在微博用户关系表中,添加新关注的好友
      Put attendPut = new Put(Bytes.toBytes(uid));
      for(String attend : attends) {
         //为当前用户添加关注的人
         attendPut.add(Bytes.toBytes("attends"),
```



```
Bytes.toBytes(attend), Bytes.toBytes(attend));
         //b、为被关注的人,添加粉丝
         Put fansPut = new Put(Bytes.toBytes(attend));
         fansPut.add(Bytes.toBytes("fans"), Bytes.toBytes(uid),
Bytes.toBytes(uid));
         //将所有关注的人一个一个的添加到 puts (List) 集合中
         puts.add(fansPut);
      puts.add(attendPut);
      relationsTBL.put(puts);
      //c.1、微博收件箱添加关注的用户发布的微博内容(content)的 rowkey
                                    contentTBL
      HTableInterface
connection.getTable(TableName.valueOf(TABLE CONTENT));
      Scan scan = new Scan();
      //用于存放取出来的关注的人所发布的微博的 rowkey
      List<br/>byte[]> rowkeys = new ArrayList<br/>byte[]>();
      for(String attend : attends) {
         //过滤扫描 rowkey,即:前置位匹配被关注的人的 uid
         RowFilter
                             filter
                                                           new
RowFilter(CompareFilter.CompareOp.EQUAL,
                                                           new
SubstringComparator(attend + " "));
         //为扫描对象指定过滤规则
         scan.setFilter(filter);
         //通过扫描对象得到 scanner
         ResultScanner result = contentTBL.getScanner(scan);
         //迭代器遍历扫描出来的结果集
         Iterator<Result> iterator = result.iterator();
         while(iterator.hasNext()){
            //取出每一个符合扫描结果的那一行数据
            Result r = iterator.next();
            for(Cell cell : r.rawCells()) {
               //将得到的 rowkey 放置于集合容器中
               rowkeys.add(CellUtil.cloneRow(cell));
            }
         }
```

#### //c.2、将取出的微博 rowkey 放置于当前操作用户的收件箱中

```
if(rowkeys.size() <= 0) return;</pre>
      //得到微博收件箱表的操作对象
      HTableInterface
                                       recTBL
connection.getTable(TableName.valueOf(TABLE RECEIVE CONTENT EMAIL
));
      //用于存放多个关注的用户的发布的多条微博 rowkey 信息
      List<Put> recPuts = new ArrayList<Put>();
      for(byte[] rk : rowkeys) {
         Put put = new Put(Bytes.toBytes(uid));
         //uid timestamp
         String rowKey = Bytes.toString(rk);
         //借取 uid
         String
                      attendUID
                                             rowKey.substring(0,
rowKey.indexOf(" "));
```



```
lona
                                   timestamp
Long.parseLong(rowKey.substring(rowKey.indexOf(" ") + 1));
          //将微博 rowkey 添加到指定单元格中
          put.add(Bytes.toBytes("info"), Bytes.toBytes(attendUID),
timestamp, rk);
         recPuts.add(put);
      recTBL.put(recPuts);
   } catch (IOException e) {
      e.printStackTrace();
   }finally{
      if(null != connection) {
          try {
             connection.close();
          } catch (IOException e) {
             // TODO Auto-generated catch block
             e.printStackTrace();
      }
   }
```

## 6.2.8 移除(取关)用户

- a、在微博用户关系表中,对当前主动操作的用户移除取关的好友(attends)
- b、在微博用户关系表中,对被取关的用户移除粉丝
- c、微博收件箱中删除取关的用户发布的微博

### 代码: public void removeAttends(String uid, String... attends)

```
/**
* 取消关注 (remove)
* a、在微博用户关系表中,对当前主动操作的用户删除对应取关的好友
* b、在微博用户关系表中,对被取消关注的人删除粉丝(当前操作人)
* c、从收件箱中,删除取关的人的微博的 rowkey
public void removeAttends(String uid, String... attends){
   //过滤数据
   if(uid == null \mid \mid uid.length() <= 0 \mid \mid attends == null \mid \mid
attends.length <= 0) return;</pre>
   HConnection connection = null;
   try {
      connection = HConnectionManager.createConnection(conf);
      //a、在微博用户关系表中, 删除已关注的好友
      HTableInterface
                                  relationsTBL
connection.getTable(TableName.valueOf(TABLE RELATIONS));
      //待删除的用户关系表中的所有数据
      List<Delete> deletes = new ArrayList<Delete>();
      //当前取关操作者的 uid 对应的 Delete 对象
      Delete attendDelete = new Delete(Bytes.toBytes(uid));
      //遍历取关,同时每次取关都要将被取关的人的粉丝-1
      for(String attend : attends) {
         attendDelete.deleteColumn(Bytes.toBytes("attends"),
```



```
Bytes.toBytes(attend));
          //b
          Delete fansDelete = new Delete(Bytes.toBytes(attend));
          fansDelete.deleteColumn(Bytes.toBytes("fans"),
Bytes.toBytes(uid));
          deletes.add(fansDelete);
      deletes.add(attendDelete);
      relationsTBL.delete(deletes);
      //c、删除取关的人的微博 rowkey 从 收件箱表中
      HTableInterface
connection.getTable(TableName.valueOf(TABLE RECEIVE CONTENT EMAIL
));
      Delete recDelete = new Delete(Bytes.toBytes(uid));
      for(String attend : attends) {
          recDelete.deleteColumn(Bytes.toBytes("info"),
Bytes.toBytes(attend));
      recTBL.delete(recDelete);
   } catch (IOException e) {
      e.printStackTrace();
```

## 6.2.9 获取关注的人的微博内容

- a、从微博收件箱中获取所关注的用户的微博 RowKey
- b、根据获取的 RowKey, 得到微博内容

#### 代码实现: public List<Message> getAttendsContent(String uid)

```
/**
* 获取微博实际内容
* a、从微博收件箱中获取所有关注的人的发布的微博的 rowkey
* b、根据得到的 rowkey 去微博内容表中得到数据
* c、将得到的数据封装到 Message 对象中
*/
public List<Message> getAttendsContent(String uid) {
   HConnection connection = null;
      connection = HConnectionManager.createConnection(conf);
      HTableInterface
                                      recTBL
connection.getTable(TableName.valueOf(TABLE RECEIVE CONTENT EMAIL
));
      //a、从收件箱中取得微博 rowKey
      Get get = new Get(Bytes.toBytes(uid));
      //设置最大版本号
      get.setMaxVersions(5);
      List<br/>byte[]> rowkeys = new ArrayList<br/>byte[]>();
      Result result = recTBL.get(get);
      for(Cell cell : result.rawCells()){
         rowkeys.add(CellUtil.cloneValue(cell));
      //b、根据取出的所有 rowkey 去微博内容表中检索数据
      HTableInterface
                                    contentTBL
```



```
connection.getTable(TableName.valueOf(TABLE CONTENT));
      List<Get> gets = new ArrayList<Get>();
      //根据 rowkey 取出对应微博的具体内容
      for(byte[] rk : rowkeys) {
          Get g = new Get(rk);
          gets.add(g);
      //得到所有的微博内容的 result 对象
      Result[] results = contentTBL.get(gets);
      List<Message> messages = new ArrayList<Message>();
      for(Result res : results) {
          for(Cell cell : res.rawCells()){
             Message message = new Message();
             String
                                       rowKey
Bytes.toString(CellUtil.cloneRow(cell));
             String
                     userid
                                               rowKey.substring(0,
rowKey.indexOf("_"));
             String
                                     timestamp
rowKey.substring(rowKey.indexOf("_") + 1);
             String
Bytes.toString(CellUtil.cloneValue(cell));
             message.setContent(content);
             message.setTimestamp(timestamp);
             message.setUid(userid);
             messages.add(message);
          }
      return messages;
   } catch (IOException e) {
      e.printStackTrace();
   }finally{
      try {
          connection.close();
      } catch (IOException e) {
          e.printStackTrace();
   return null;
```

### 6.2.10 测试

-- 测试发布微博内容

public void testPublishContent(WeiBo wb)

-- 测试添加关注

public void testAddAttend(WeiBo wb)

-- 测试取消关注

public void testRemoveAttend(WeiBo wb)

-- 测试展示内容

public void testShowMessage(WeiBo wb) 代码:



```
/**
* 发布微博内容
* 添加关注
* 取消关注
* 展示内容
public void testPublishContent(WeiBo wb) {
   wb.publishContent("0001", "今天买了一包空气,送了点薯片,非常开心!!");
   wb.publishContent("0001", "今天天气不错。");
public void testAddAttend(WeiBo wb) {
   wb.publishContent("0008", "准备下课!");
   wb.publishContent("0009", "准备关机!");
   wb.addAttends("0001", "0008", "0009");
public void testRemoveAttend(WeiBo wb) {
   wb.removeAttends("0001", "0008");
public void testShowMessage(WeiBo wb) {
   List<Message> messages = wb.getAttendsContent("0001");
   for(Message message : messages) {
      System.out.println(message);
public static void main(String[] args) {
   WeiBo weibo = new WeiBo();
   weibo.initTable();
   weibo.testPublishContent(weibo);
   weibo.testAddAttend(weibo);
   weibo.testShowMessage(weibo);
   weibo.testRemoveAttend(weibo);
   weibo.testShowMessage(weibo);
```